Переосмысление Picodata в качестве cluster-first СУБД

Ярослав Дынников

Picodata

Saint HighLoad++

Слайды: https://rosik.github.io/2024-shl

План доклада

1. Питч
2. Архитектура и алгоритмы
3. Конкурентные отличия
4. Расширение функциональности

Picodata — это

- Distributed SQL

Picodata — это

- Distributed SQL
- Sharding, replication

Picodata — это

- Distributed SQL
- Sharding, replication
- In-memory

Picodata — это

- Distributed SQL
- Sharding, replication
- In-memory, single-threaded

Picodata — это

- Distributed SQL
- Sharding, replication
- In-memory, single-threaded
- Горизонтальное масштабирование

Picodata — это

- Distributed SQL
- Sharding, replication
- In-memory, single-threaded
- Горизонтальное масштабирование
- ...

PICODATA

Маленькие, быстрые данные

Катакомбы Picodata

Обзорная экскурсия

Saint HighLoad++

Что было до

Что было до

Tarantool

In-memory СУБД и сервер приложений на Lua
Get your data in RAM. Get compute close to data. Enjoy the performance

Что было до

Tarantool

In-memory СУБД и сервер приложений на Lua
Get your data in RAM. Get compute close to data. Enjoy the performance

Vshard

Модуль шардирования на основе виртуальных бакетов

Что было до

Tarantool

In-memory СУБД и сервер приложений на Lua
Get your data in RAM. Get compute close to data. Enjoy the performance

Vshard

Модуль шардирования на основе виртуальных бакетов

Cartridge

Фреймворк для разработки распределенных приложений

Особенности экосистемы

Performance

Быстро, но не всегда предсказуемо (LuaJIT, GC)

Особенности экосистемы

Performance

Быстро, но не всегда предсказуемо (LuaJIT, GC)

Функциональные

SQL есть, но в рамках одного узла

Особенности экосистемы

Performance

Быстро, но не всегда предсказуемо (LuaJIT, GC)

Функциональные

SQL есть, но в рамках одного узла

Разработка

Очень интересно, но сложно

Особенности экосистемы

Performance

Быстро, но не всегда предсказуемо (LuaJIT, GC)

Функциональные

SQL есть, но в рамках одного узла

Разработка

Очень интересно, но сложно

Эксплуатация

То слишком гибко, то слишком жестко (two-phase commit)

План

1. Заменить two-phase commit на Raft
2. Реализовать распределенный SQL
3. И все это на Rust
4. ???
5. Profit

Управление кластером

Saint HighLoad++

Raft

Алгоритм для решения задач консенсуса
в сети ненадежных вычислений

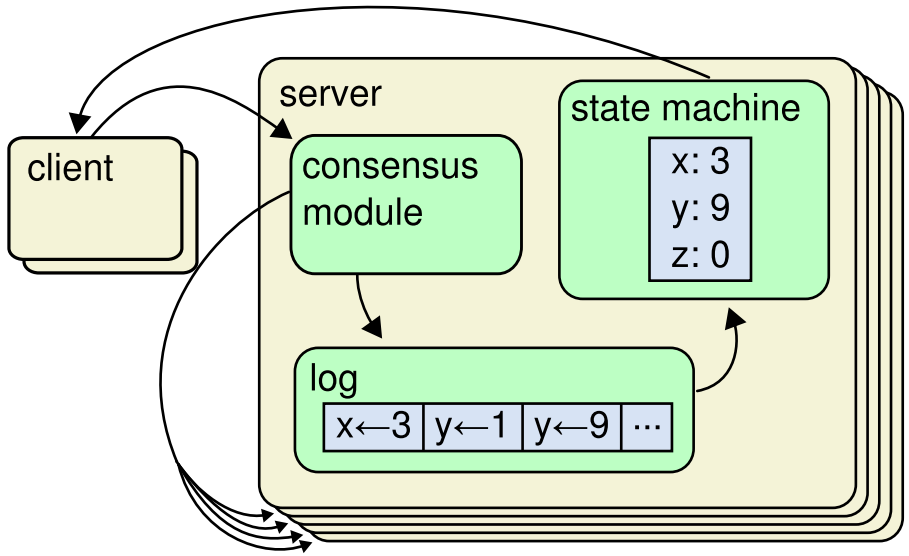

Raft

Алгоритм для решения задач консенсуса
в сети ненадежных вычислений

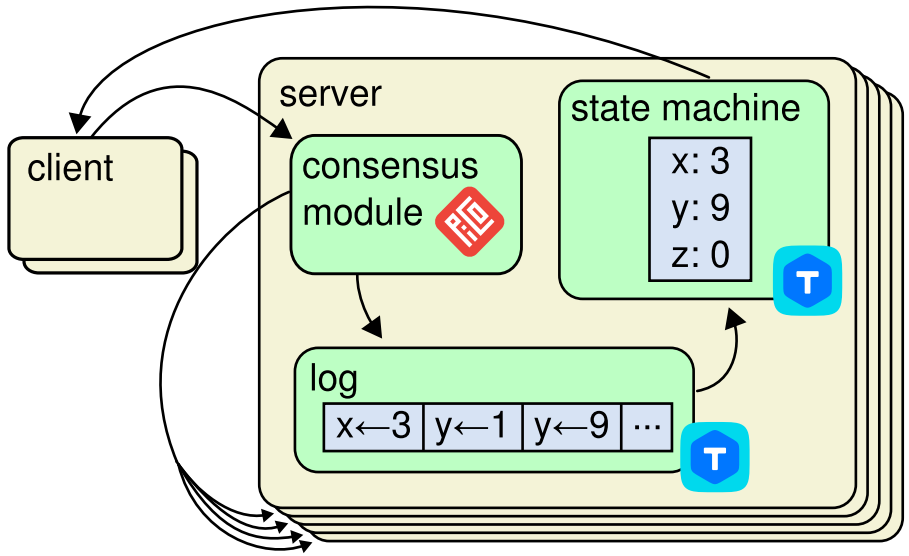

Cluster manager

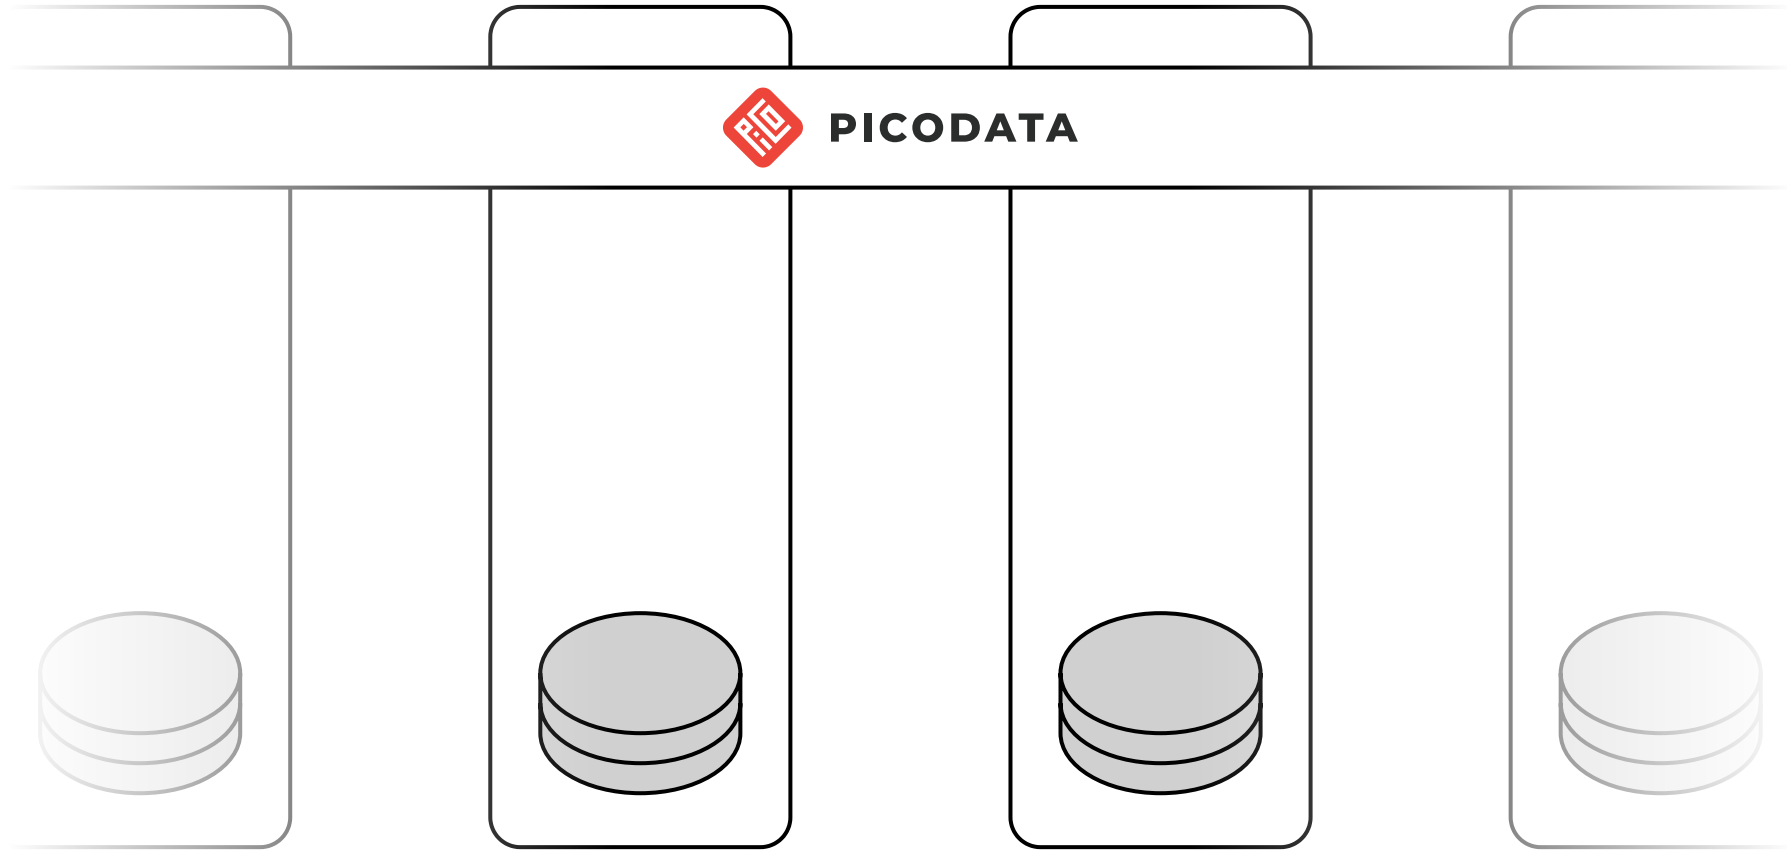

Cluster manager

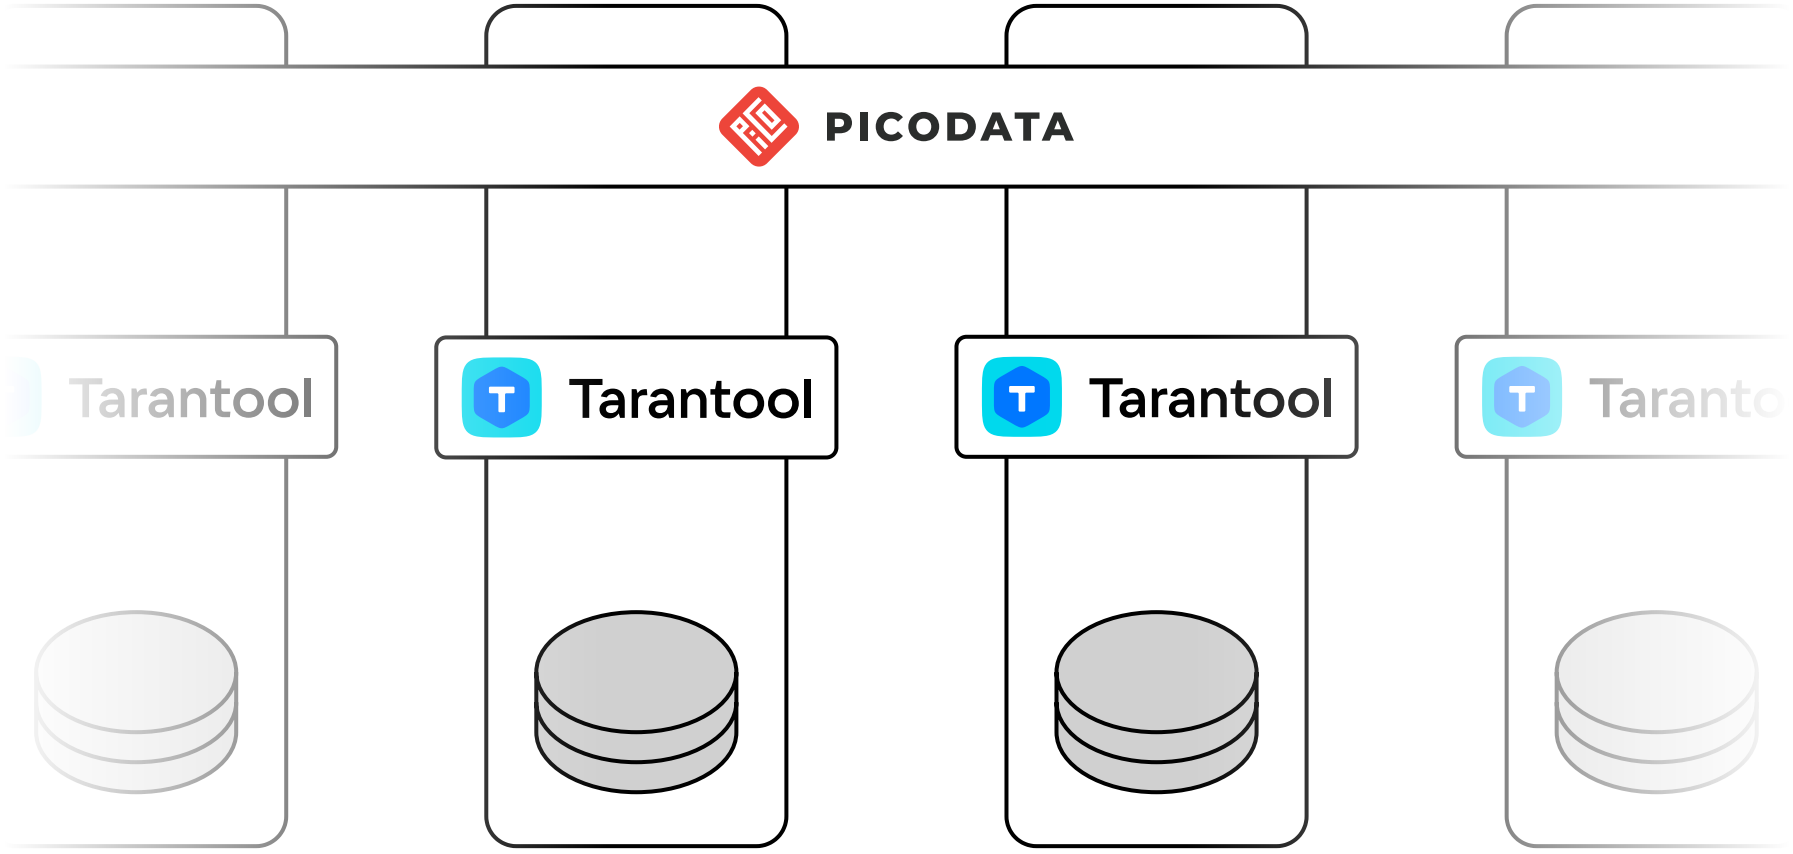

Cluster manager

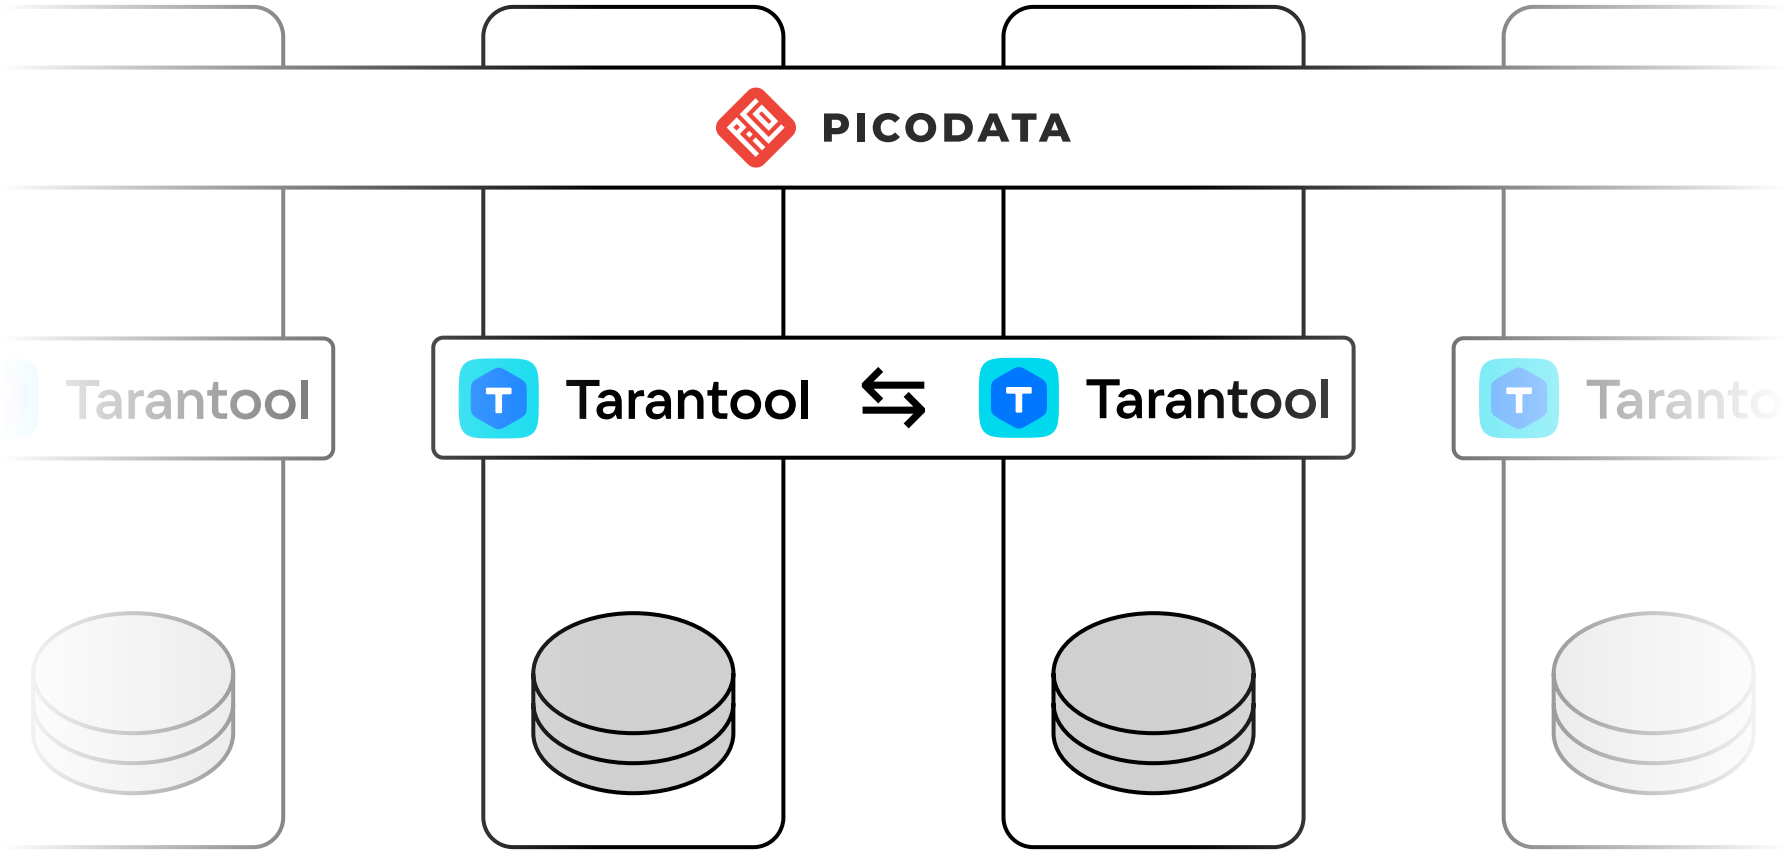

- И вот тут маленький взрыв мозга обычно

Cluster manager

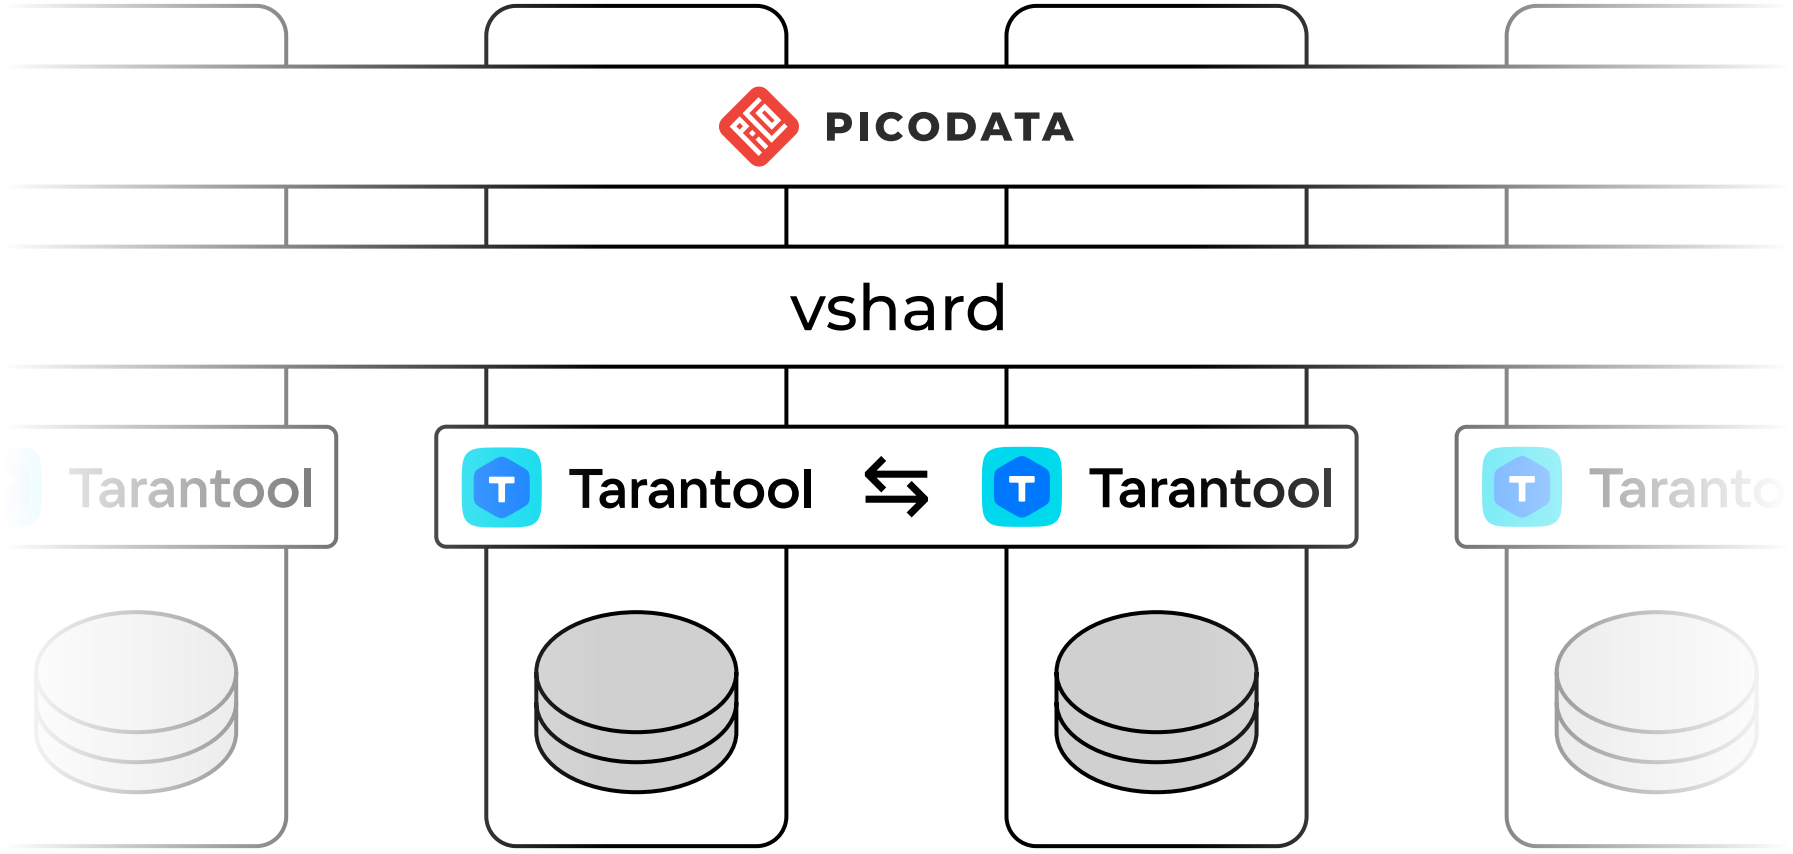

Иерархия

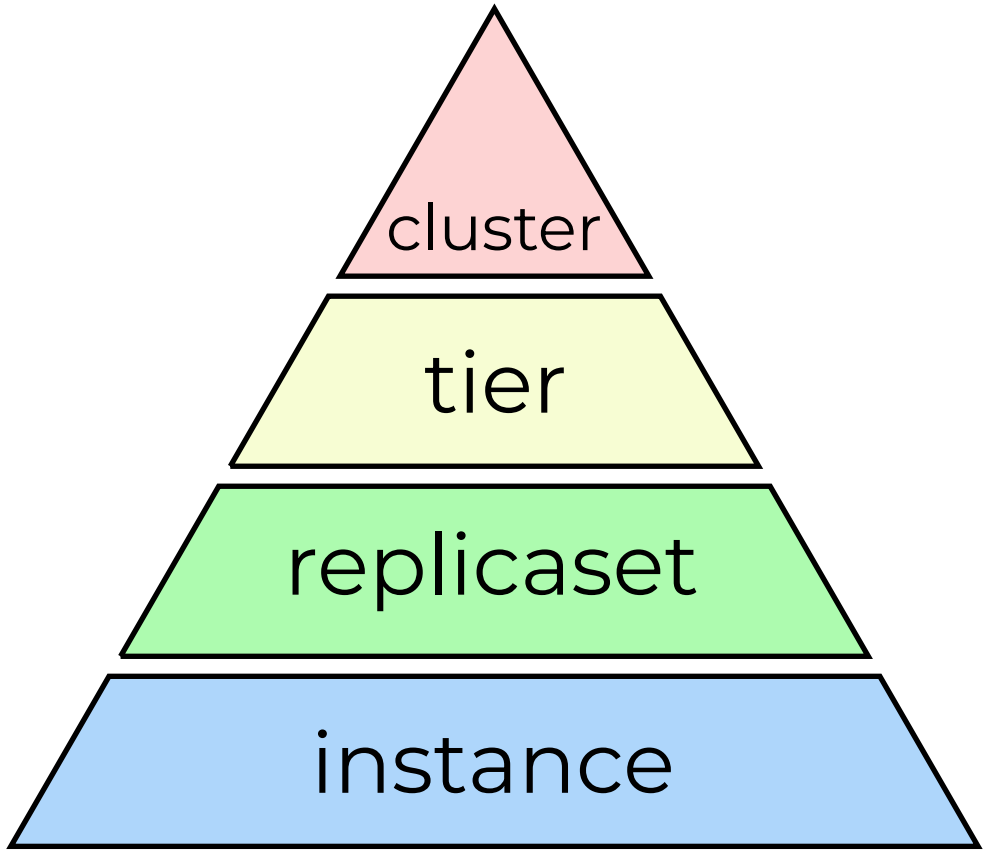

Описание структуры

INSTANCE	
	raft_id
PK	instance_id
FK	replicaset_id
	current_state
	target_state

State: Online ⇆ Offline; generation

Важно: не status, а state!

Лидер, фолловер, кандидат

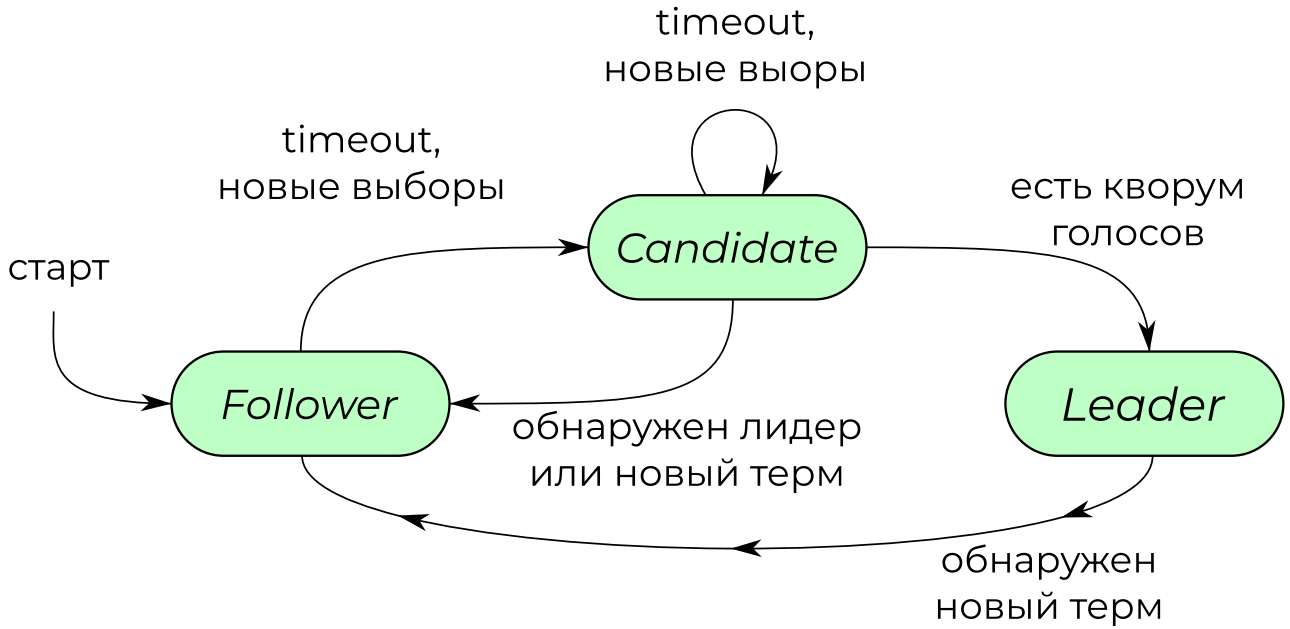

Leader единственный пишет в журнал + пингует окружающих

Лидер, фолловер, кандидат

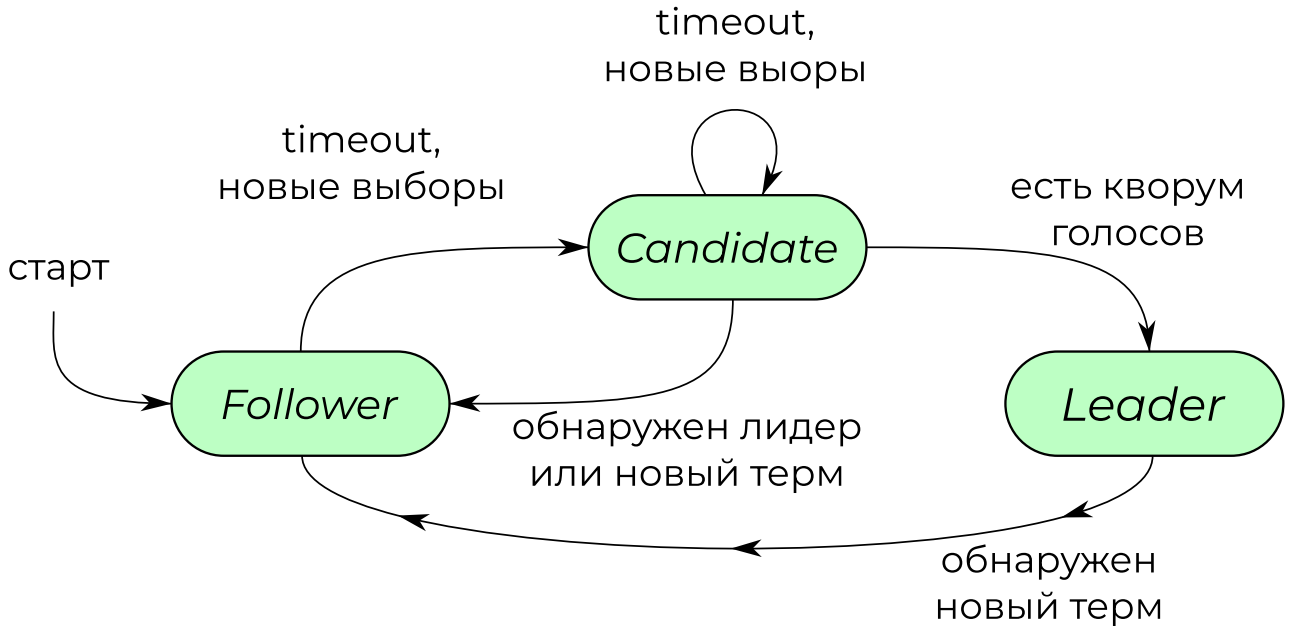

Leader единственный пишет в журнал + пингует окружающих
Follower пассивен, не отправляет никаких запросов

Лидер, фолловер, кандидат

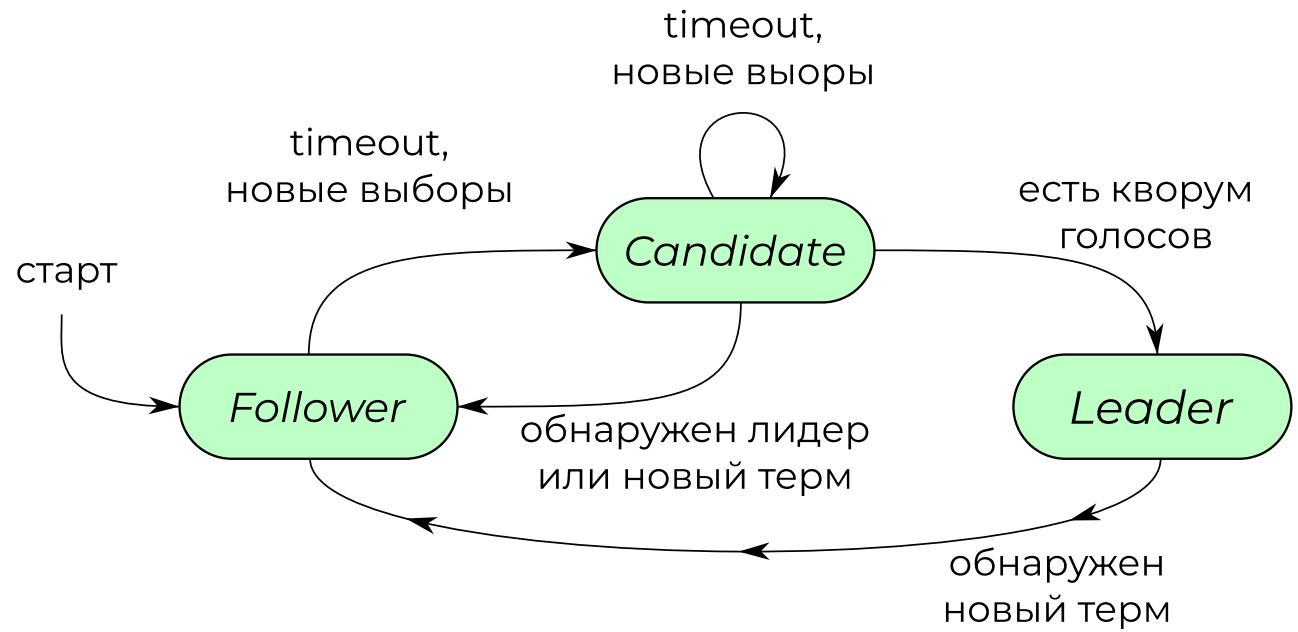

Leader единственный пишет в журнал + пингует окружающих
Follower пассивен, не отправляет никаких запросов
Candidate проводит голосование

Отказоустойчивость

- Сотни инстансов в кластере
- 5 из них *voters*, остальные *learners*
- 1 из них *Leader*, остальные *Follower*

Работа с данными

Saint HighLoad++

Хранение данных

- Таблицы бывают *шардированные* и *глобальные*
- Схема данных единая на весь кластер
- Доступ к данным посредством языка SQL

Распределенный SQL

INNER JOIN
LEFT OUTER JOIN
WHERE
WHERE ... IN
GROUP BY
HAVING
ORDER BY
UNION ALL
DISTINCT
EXCEPT DISTINCT

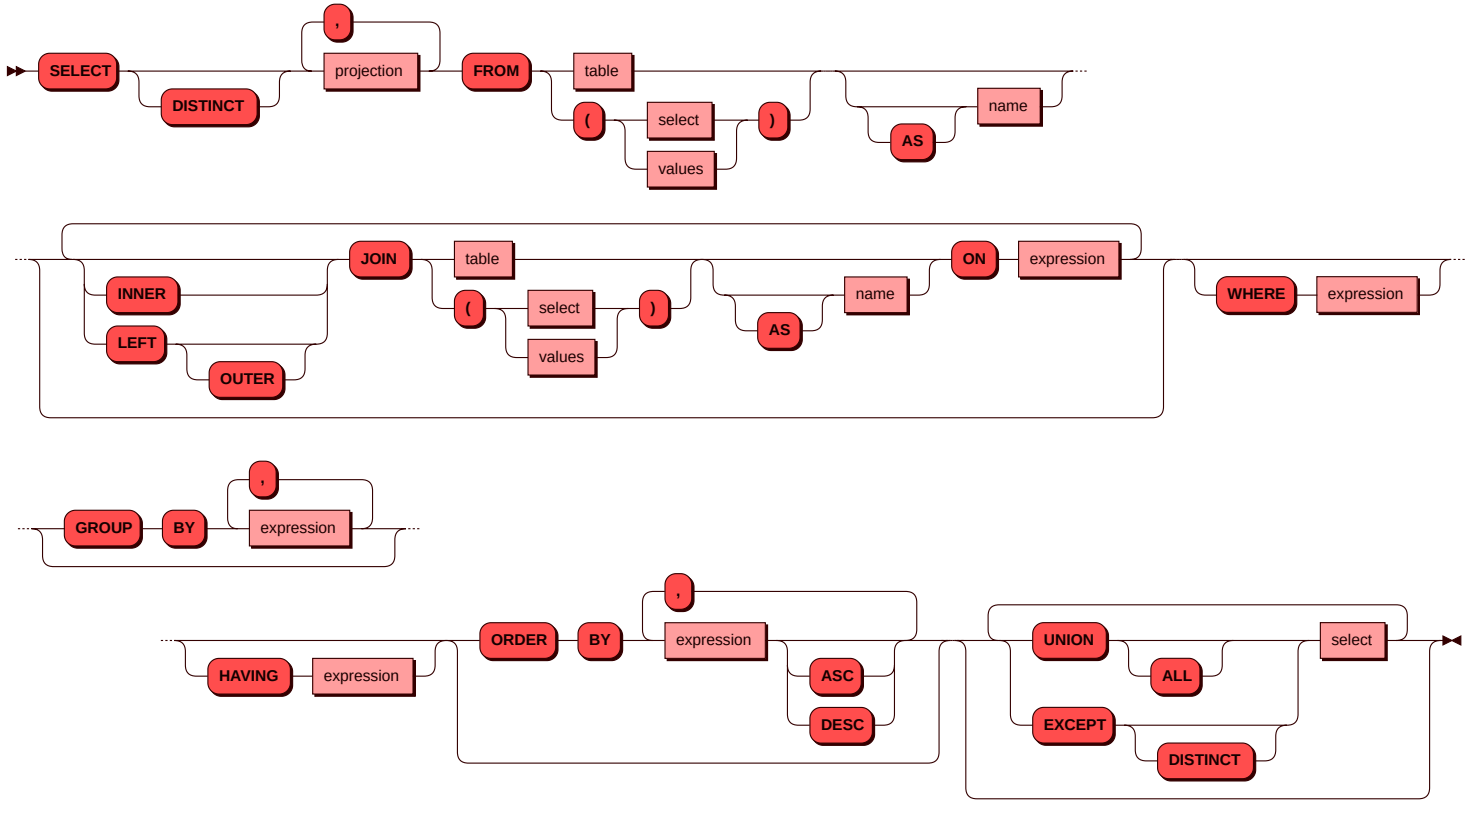

https://docs.picodata.io/picodata/24.4/sql_index/

AST

AST == abstract syntax tree

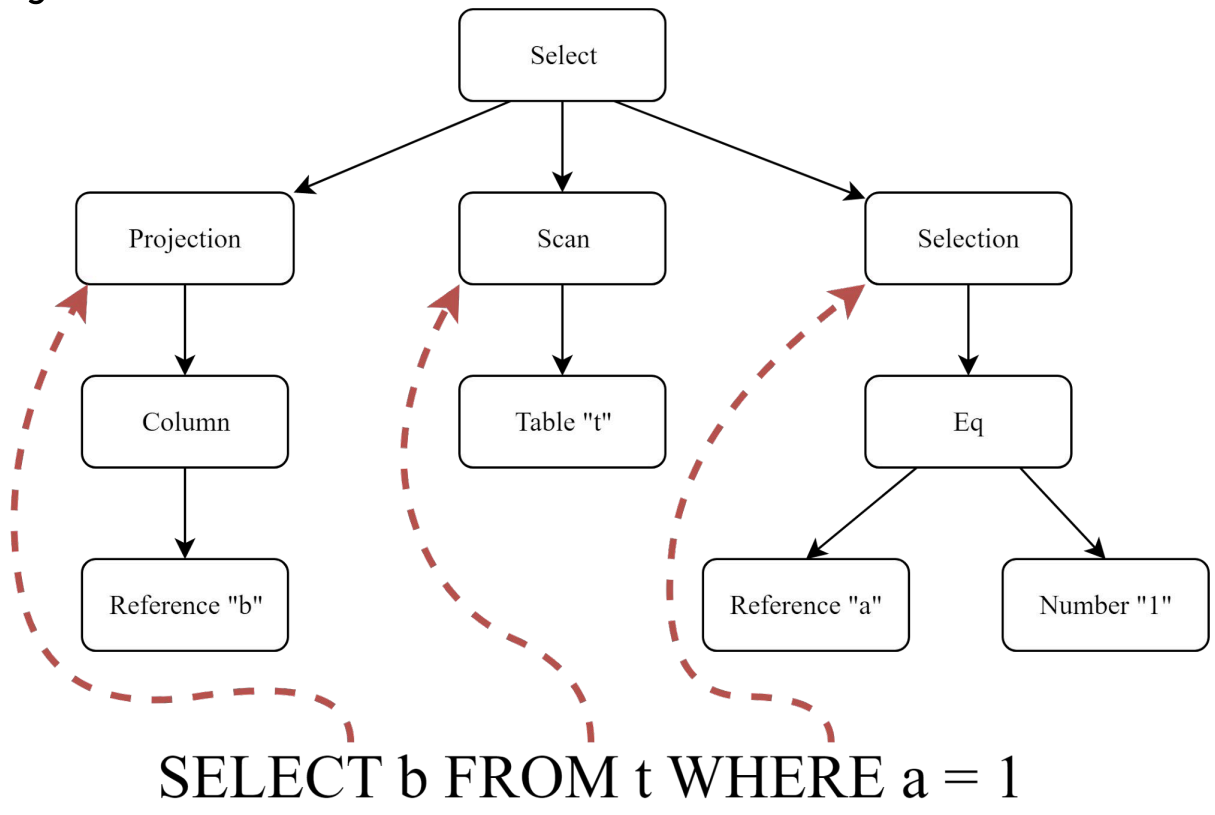

План запроса (IR)

IR == intermediate representation == plan

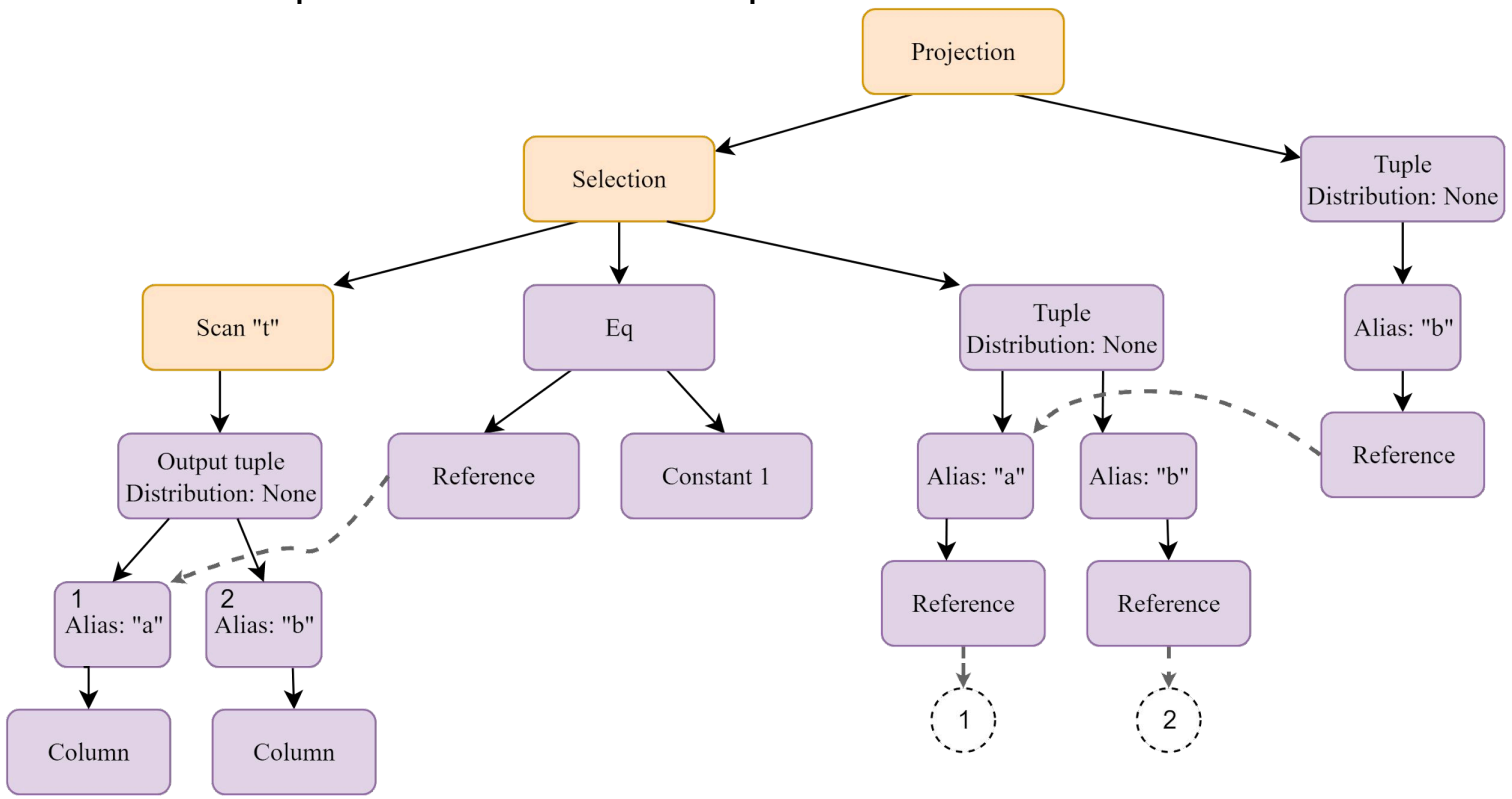

SELECT b FROM t WHERE a = 1

План запроса

IR == intermediate representation == plan

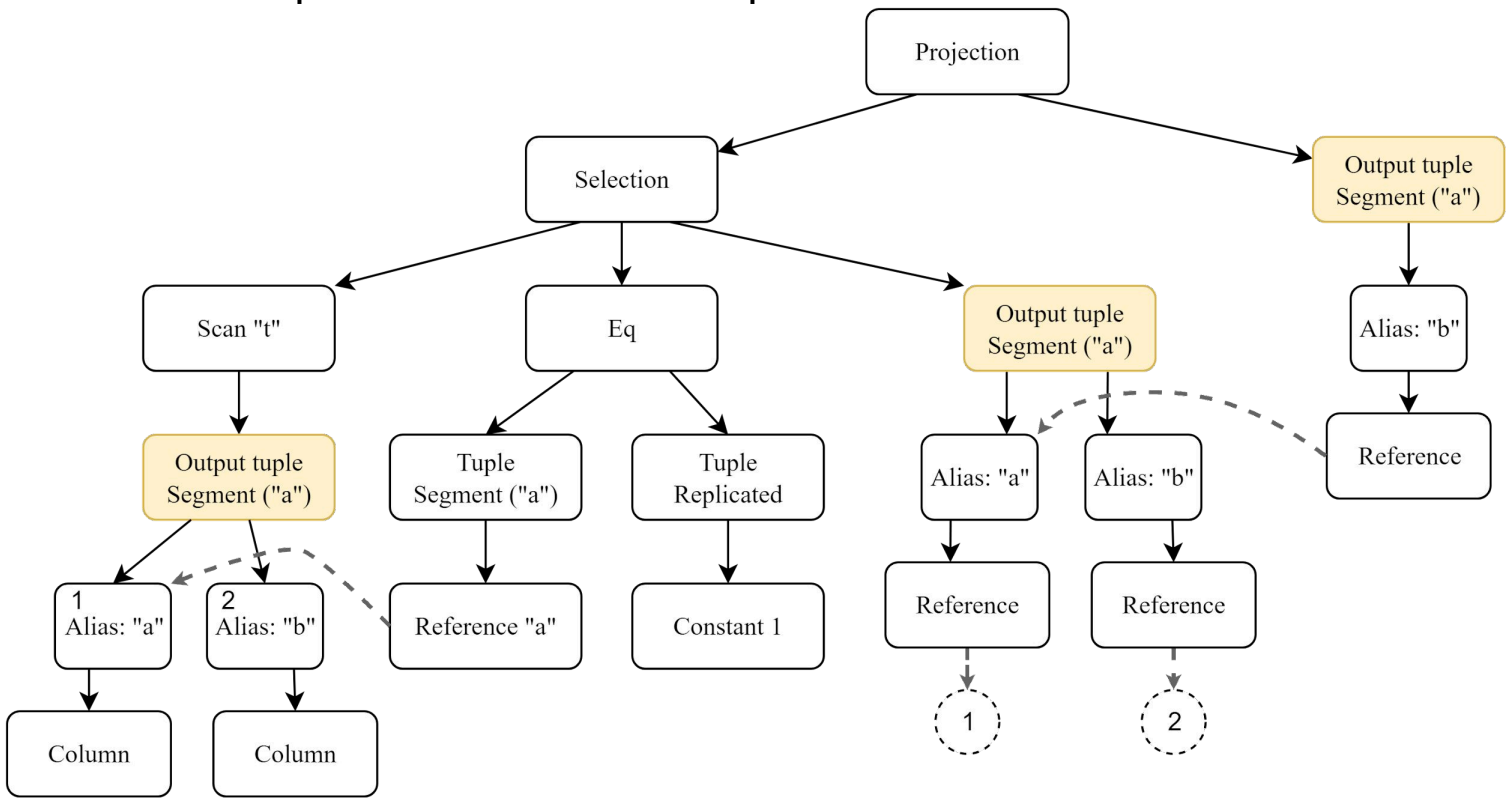

SELECT b FROM t WHERE a = 1

Обработка запроса (1)

Router

SQL → AST → IR → *execute*

Bucket discovery

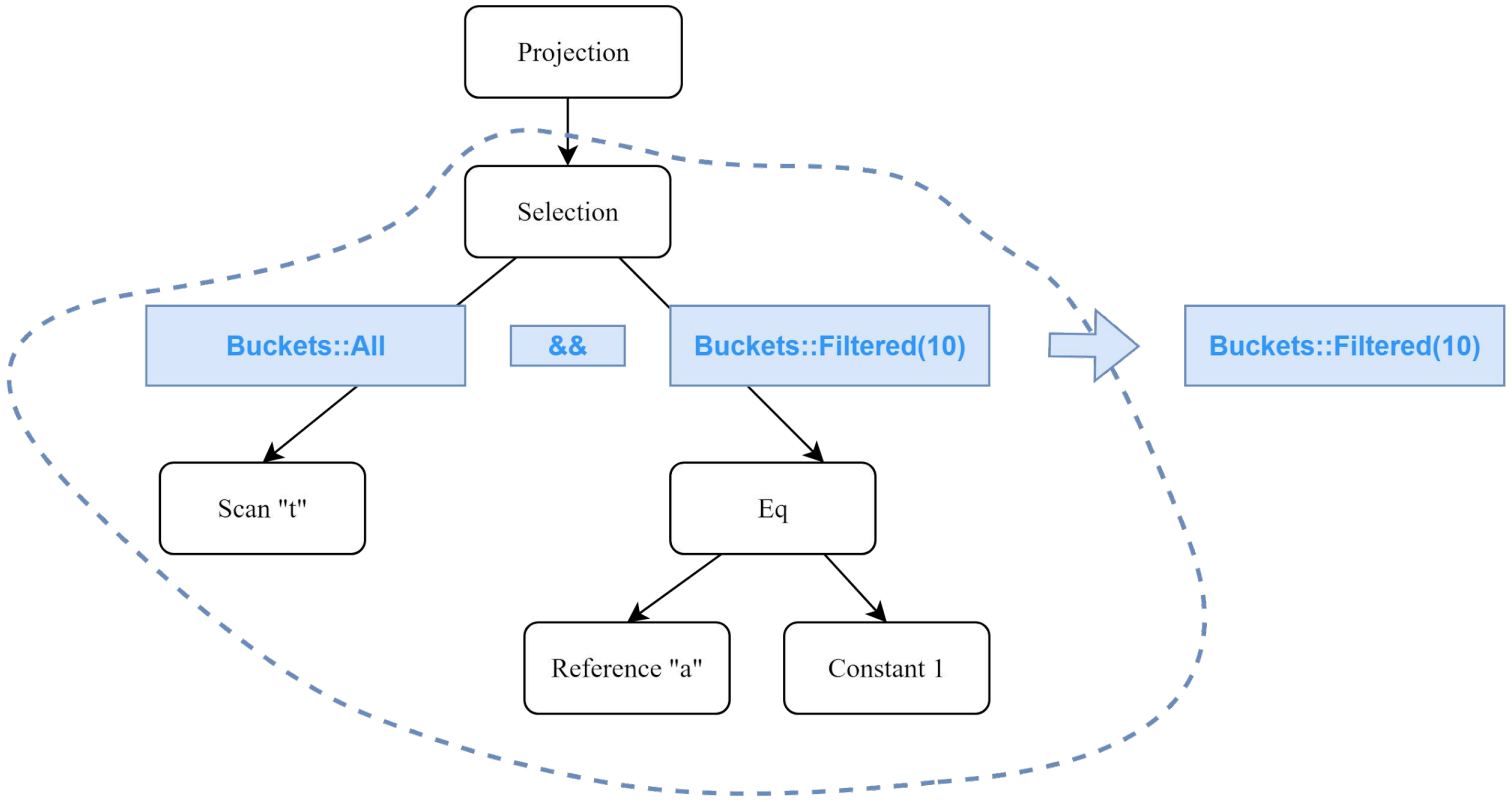

SELECT b FROM t WHERE a = 1

IR → VDBE

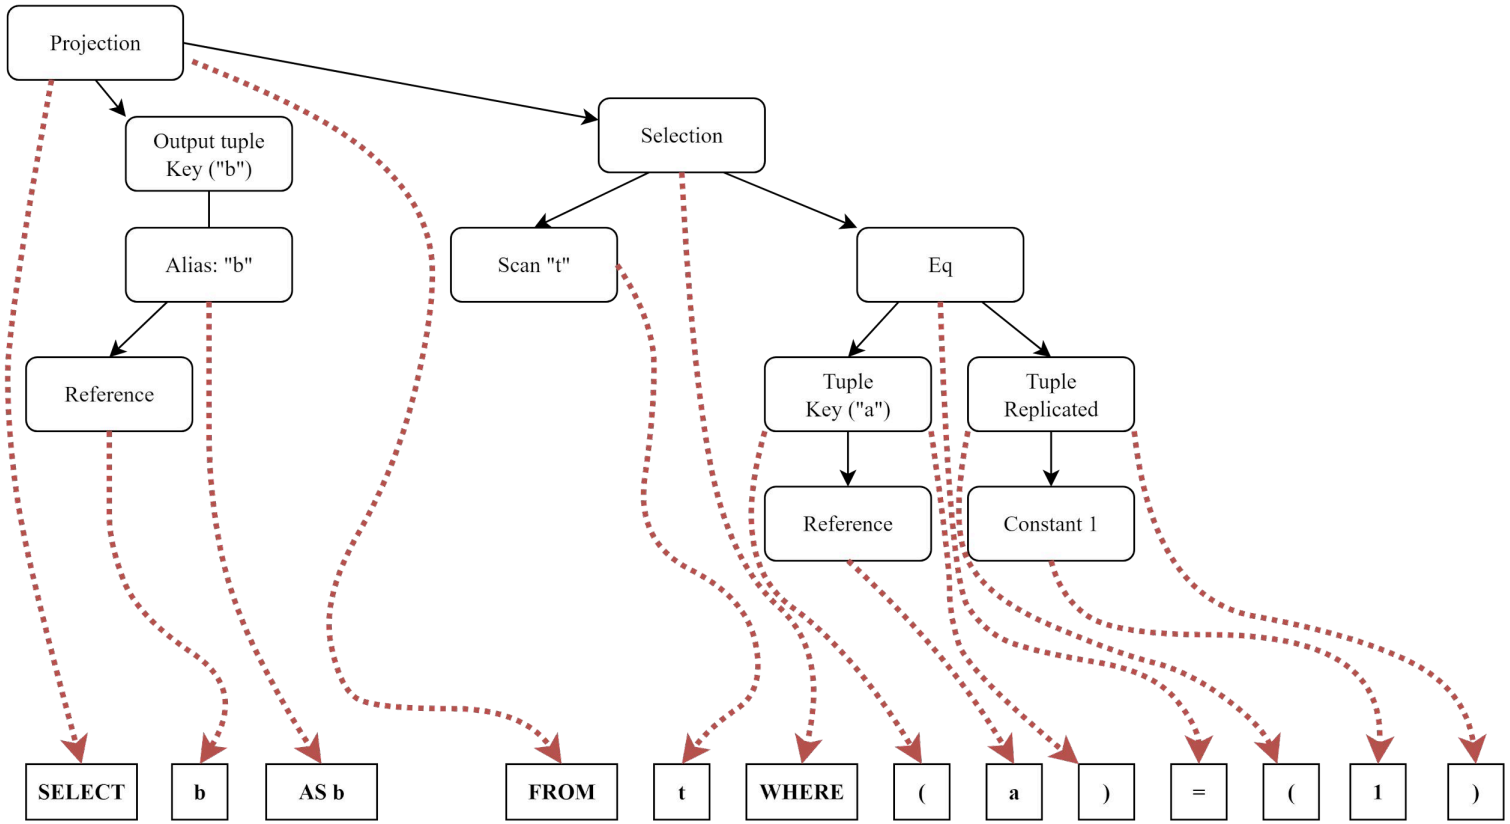

- Теперь мы знаем где искать данные и можно

Обработка запроса (2)

Router

SQL → AST → IR → execute

Executor

IR subtree → bucket discovery →
→ map → VDBE ops → reduce

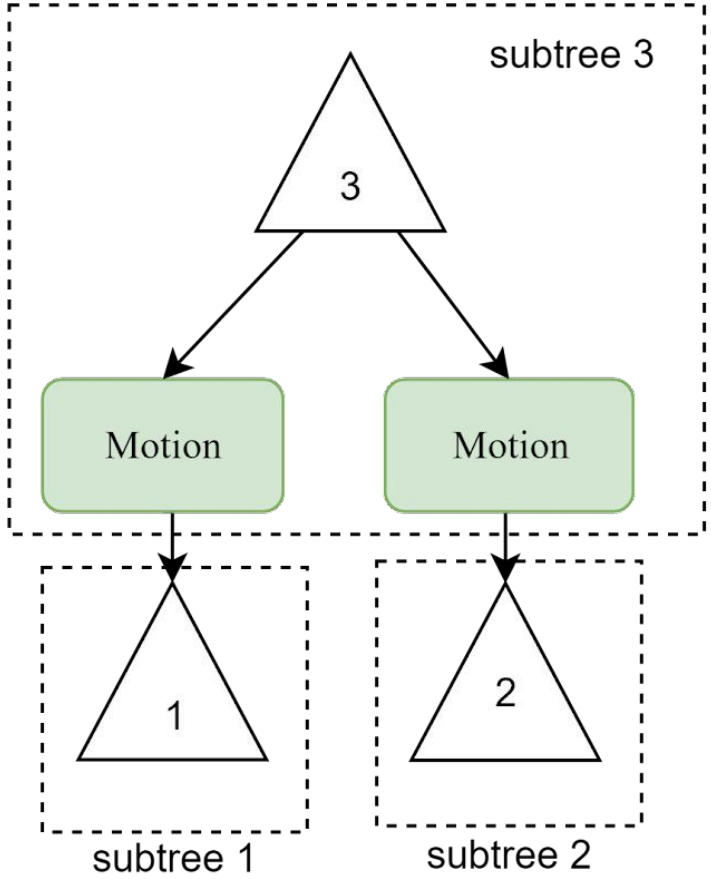

Итого

История Tarantool

Алгоритм Raft

Иерархия — инстансы, репликасеты, тиры, кластер

Не status, а state

Лидер, фолловер, кандидат

Динамическое переключение голосующих узлов

Распределенный SQL

Материалы

- Слайды: https://rosik.github.io/2024-shl
- Picodata: https://picodata.io/
- Telegram: @picodataru

Обратная связь:

https://conf.ontico.ru/online/shl2024/details/5492379

HL 2024 Saint HighLoad++

Состояние записей в raft-журнале

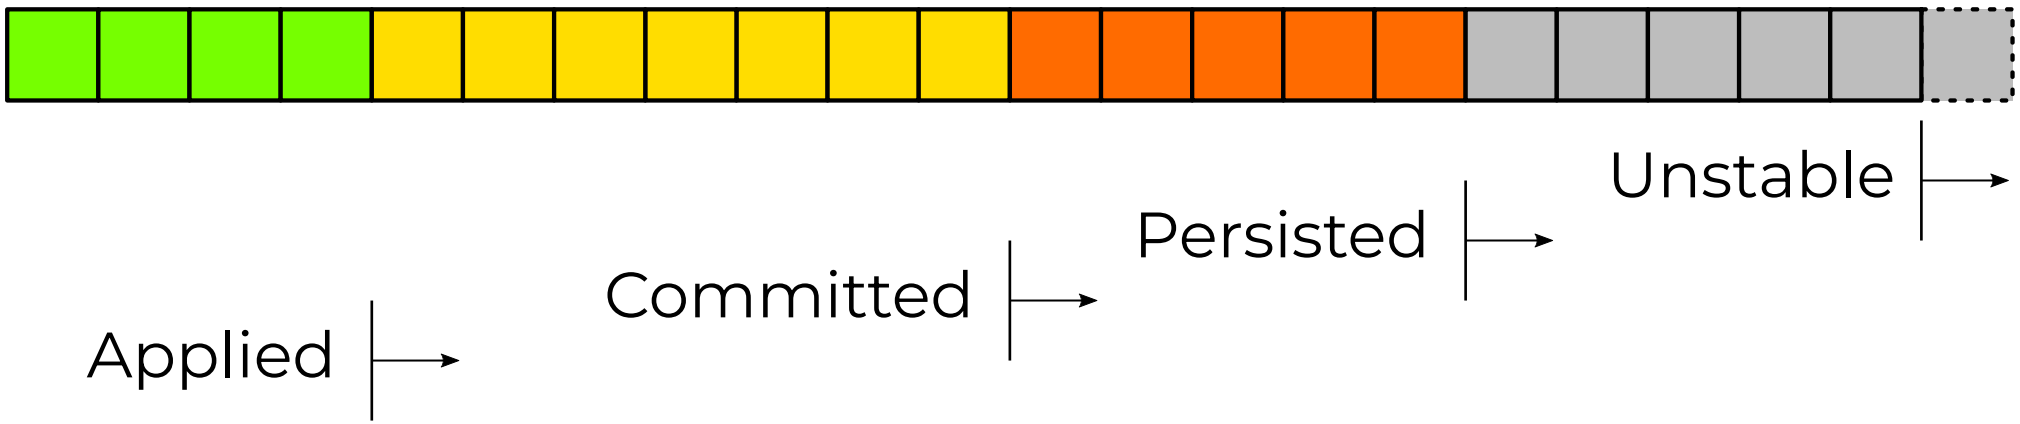

Виды операций в raft-журнале

```rust
pub enum Op {
    Nop,
    Dml(Dml),
    DdlPrepare { schema_version: u64, ddl: Ddl },
    DdlCommit,
    DdlAbort,
    Acl(Acl),
}
```